

基于监督学习与物理残差修正的 Lorenz 混沌系统预测研究

小组成员：钟兴涛、黄宇轩、郝致祺

课程名称：人工智能导论

2026 年 5 月 20 日

摘要

本文以 Lorenz 混沌系统为对象，使用 AI 导论课程中的回归、树模型和神经网络方法进行监督学习预测。实验表明，Linear Regression、Random Forest 和 MLP 可以在短时间尺度上学习局部状态转移，但随着 prediction horizon 增大，状态误差明显上升；在 recursive rollout 中，模型会不断使用自身预测作为下一步输入，误差因此持续累积。为了改善直接预测的局限，本文进一步使用 Residual MLP 学习状态变化量，并使用 Hybrid correction 学习不完美物理模型的残差。结果表明，在当前参数偏差设定（真实系统 $\rho = 28$ ，不完美物理模型 $\rho = 26$ ）下，物理模型与机器学习结合可以显著改善一步预测和短中期递归推演效果，体现了 AI for Science 中机器学习辅助科学建模的思想。本文不将结论扩展为“机器学习解决了混沌系统长期预测”，而是强调 Lorenz 系统短期可学、长期受限，残差学习和物理残差修正在有限设定下具有明确价值。

关键词：Lorenz 系统；监督学习；Linear Regression；Random Forest；MLP；Residual MLP；Hybrid correction；AI for Science

1 引言

1.1 Lorenz 系统与混沌预测问题

Lorenz 系统是非线性动力系统和混沌理论中的经典模型 [1]。它由确定性微分方程控制，但由于存在非线性耦合和初值敏感性，长期逐点预测非常困难。对课程项目而言，Lorenz 系统适合作为“AI for Science”小案例：一方面，系统方程清楚、数据可以由数值模拟生成；另一方面，混沌误差放大会限制普通黑箱模型的长期预测能力。

1.2 AI 导论课程模型与科学预测任务

本项目主要使用 AI 导论课程中涉及的回归、树模型和神经网络方法。Linear Regression 对应基础回归模型，Random Forest 对应树模型，MLP 和 Residual MLP 对应神经网络模型。在此基础上，本文将监督学习任务从直接预测未来状态扩展为物理模型残差修正，以体现 AI for Science 中机器学习辅助科学建模的思想。

因此，本文不追求堆叠大量复杂模型，而是把重点放在任务定义和预测边界分析上：普通监督学习模型能否学习短期状态转移？prediction horizon 增大后误差如何变化？recursive rollout 中误差为什么会累积？如果已有一个参数有偏的物理模型，机器学习能否作为残差修正器而不是完全替代物理模型？

1.3 本文思路：从直接监督学习预测到物理残差修正

本文贡献压缩为三点：

1. 将 Lorenz 系统预测构造为监督学习回归任务，并比较回归、树模型和神经网络方法；
2. 通过 prediction horizon 和 recursive rollout 分析普通黑箱模型的预测边界；
3. 引入 Residual MLP 和 Hybrid correction，说明残差学习和物理模型修正在科学预测中的价值。

2 数据与任务定义

2.1 Lorenz 方程

Lorenz 系统由以下三个耦合常微分方程组成：

$$\frac{dx}{dt} = \sigma(y - x), \quad (1)$$

$$\frac{dy}{dt} = x(\rho - z) - y, \quad (2)$$

$$\frac{dz}{dt} = xy - \beta z. \quad (3)$$

本文真实系统采用经典参数：

$$\sigma = 10, \quad \rho = 28, \quad \beta = \frac{8}{3}. \quad (4)$$

在该参数组合下，轨迹形成典型 Lorenz 吸引子。图 1 展示了本文数据生成所使用的三维轨迹。

Lorenz 系统三维吸引子




图 1: Lorenz 系统三维吸引子轨迹。轨迹在两个翼之间不规则切换，说明本文预测任务发生在非线性混沌系统上。

2.2 数据生成

本文不使用外部数据集，而是通过 `scipy.integrate.solve_ivp` 数值求解 Lorenz 方程 [3]。基础轨迹初始状态为 $(1, 1, 1)$ ，模拟时间范围为 $[0, 50]$ ，采样点数为 10000，采样步长约为

$$\Delta t \approx 0.00500005. \quad (5)$$

所有监督学习实验均按时间顺序切分数据：前 80% 作为训练集，后 20% 作为测试集，不随机打乱，以避免未来信息进入训练过程。输入特征标准化器只在训练集上拟合，然后应用到训练集和测试集。

2.3 直接状态预测任务

令系统状态向量为

$$\mathbf{s}_t = (x_t, y_t, z_t), \quad (6)$$

直接监督学习预测任务定义为:

$$f_\theta(\mathbf{s}_t) \approx \mathbf{s}_{t+k}. \quad (7)$$

其中 k 是 prediction horizon。本文主文只展示 $k = 10, 100, 500$ 的代表性结果，完整结果保存在 `results/horizon_results.csv`。此外，课程原始任务为从 (x_t, y_t, z_t) 预测 $x(t + 10\Delta t)$ ，对应结果保存在 `results/model_metrics.csv`。

2.4 物理残差修正任务

为了模拟真实科学建模中“已有近似物理模型但参数有偏”的情况，本文构造一个不完美 Lorenz 物理模型。真实系统使用 $\rho = 28$ ，不完美物理模型使用

$$\rho = 26. \quad (8)$$

先由不完美物理模型预测一步未来状态 $\mathbf{s}_{t+1}^{phys}$ ，再定义残差:

$$\mathbf{r}_{t+1} = \mathbf{s}_{t+1} - \mathbf{s}_{t+1}^{phys}. \quad (9)$$

机器学习模型学习该残差，而不是直接从零学习完整物理演化。

2.5 评价指标

对单变量课程原始任务，本文报告 RMSE、MAE 和 R^2 。对三维状态预测，本文使用状态 RMSE:

$$RMSE_{state} = \sqrt{\frac{1}{n} \sum_{i=1}^n \|\mathbf{s}_i - \hat{\mathbf{s}}_i\|_2^2}. \quad (10)$$

同时报告三个分量 R^2 的平均值 R_{mean}^2 。在 recursive rollout 分析中，本文还使用有效预测时间 (valid prediction time): 当逐步状态误差首次超过经验阈值 5.5234 时，认为逐点预测失效，并将对应物理时间换算为 Lyapunov time。该阈值只是经验标准，因此需要与误差曲线共同解读。

3 方法

3.1 Linear Regression: 回归基线

Linear Regression 学习从当前状态到未来状态的线性映射。它对应课程中的基础回归模型，也可视为对局部状态转移的线性近似。由于 Lorenz 方程包含 xz 、 xy 等非线性项，线性模型表达能力有限，但它提供了清晰的回归基线。

3.2 Random Forest: 树模型

Random Forest Regressor 是本文的树模型代表。它可以拟合非线性状态转移关系，并且训练过程相对稳定。本文使用它观察传统非线性机器学习模型在不同 prediction horizon 下的短期拟合能力和长期退化现象 [2]。

3.3 MLP: 神经网络直接预测

Direct MLP 使用多层感知机直接学习

$$f_{\theta}(\mathbf{s}_t) \approx \mathbf{s}_{t+k}. \quad (11)$$

该模型对应课程中的神经网络内容。MLP 能拟合非线性映射，因此在短期预测中通常优于线性模型；但在长 horizon 或 recursive rollout 中，预测误差仍会被混沌动力学放大。

3.4 Residual MLP: 状态增量学习

Residual MLP 不直接预测未来状态，而是学习状态变化量：

$$\Delta \mathbf{s} = \mathbf{s}_{t+k} - \mathbf{s}_t, \quad (12)$$

$$g_{\theta}(\mathbf{s}_t) \approx \Delta \mathbf{s}. \quad (13)$$

最终预测为

$$\hat{\mathbf{s}}_{t+k} = \mathbf{s}_t + g_{\theta}(\mathbf{s}_t). \quad (14)$$

这一形式更接近连续动力系统数值积分中的“当前状态 + 局部增量”，因此比直接学习未来状态更适合中短期状态转移。

3.5 Hybrid Correction: 物理模型残差修正

Hybrid correction 的核心思想不是用机器学习替代物理模型，而是让不完美物理模型承担主要演化，再由机器学习修正其系统误差。本文先由 $\rho = 26$ 的不完美物理模型得到一步预测：

$$\mathbf{s}_{t+1}^{phys}, \quad (15)$$

然后让机器学习模型学习

$$h_{\theta}(\mathbf{s}_t) \approx \mathbf{r}_{t+1} = \mathbf{s}_{t+1} - \mathbf{s}_{t+1}^{phys}. \quad (16)$$

最终预测为

$$\hat{\mathbf{s}}_{t+1} = \mathbf{s}_{t+1}^{phys} + h_{\theta}(\mathbf{s}_t). \quad (17)$$

表 1 总结了 Direct MLP、Residual MLP 和 Hybrid MLP 的学习目标差异。

表 1: Direct MLP、Residual MLP 和 Hybrid MLP 的任务形式对比。该表统一了本文从直接预测到残差修正的递进结构。

方法	学习目标	解释
Direct MLP	$\mathbf{s}_{t+k}$	直接预测未来状态
Residual MLP	$\mathbf{s}_{t+k} - \mathbf{s}_t$	学习状态变化量
Hybrid MLP	$\mathbf{s}_{t+1} - \mathbf{s}_{t+1}^{phys}$	学习物理模型误差

4 实验结果

4.1 直接监督学习预测结果

表 2 给出课程原始单变量任务 $x(t+10\Delta t)$ 的结果,数值来自 `results/model_metrics.csv`。这里删除了 Persistence Model 的主文重点,只保留课程对应的回归、树模型和神经网络模型。可以看到,Random Forest 和 MLP 在短期单变量预测中取得较低误差,说明短时间尺度上的局部状态转移可被非线性模型拟合。

表 2: 课程原始短期预测任务结果 (来自 `model_metrics.csv`)。该表说明短期局部映射可学习, 但不能推出长期混沌预测已解决。

模型	RMSE	MAE	R^2
Linear Regression	0.5457	0.4437	0.9952
Random Forest	0.0805	0.0507	0.9999
MLP	0.0757	0.0599	0.9999

4.2 Prediction horizon 对误差的影响

表 3 展示 $k = 10, 100, 500$ 下的三维状态预测结果, 数值来自 `results/horizon_results.csv`。随着 horizon 增大, 各模型状态 RMSE 明显上升, 说明普通监督学习模型的预测能力存在时间尺度边界。

表 3: 不同 prediction horizon 下的三维状态预测结果 (来自 `horizon_results.csv`)。完整 horizon 结果见 CSV 文件。

Horizon	模型	State RMSE	R^2_{mean}
10	Linear Regression	4.7791	0.9028
10	Random Forest	0.3425	0.9995
10	MLP	0.4130	0.9993
100	Linear Regression	15.4505	-0.0793
100	Random Forest	3.1292	0.9569
100	MLP	2.1529	0.9800
500	Linear Regression	15.2982	-0.0292
500	Random Forest	10.9789	0.4714
500	MLP	14.0980	0.1245




图 2: 不同 prediction horizon 下的状态 RMSE。随着 horizon 增大, 各模型误差明显上升, 说明普通监督学习模型的预测能力存在时间尺度边界。

4.3 Recursive rollout 中的误差累积

直接预测 $\mathbf{s}_{t+k}$ 时, 每个测试样本仍使用真实当前状态作为输入; 而 recursive rollout 只在初始时给定一次真实状态, 之后不断使用模型自己的预测作为下一步输入。因此, 早期误差会进入后续输入并被继续放大。

表 4 给出 500 步 rollout 结束时的累计状态 RMSE, 数值来自 `results/rollout_results.csv`。Random Forest 在该实验中低于 Linear Regression 和 MLP, 但三者都出现了明显长期误差累积。

表 4: 500 步 recursive rollout 的最终累计状态 RMSE (来自 `rollout_results.csv`)。

模型	Rollout 步数	最终累计 State RMSE
Linear Regression	500	20.2244
Random Forest	500	14.5356
MLP	500	19.8142




图 3: 递归多步推演中的误差累积曲线。模型自身误差会被反复输入下一步，因此短期一步误差会逐渐转化为长期轨迹偏离。

4.4 Residual MLP 的改进效果

表 5 比较 Direct MLP 与 Residual MLP, 数值来自 `results/model_enhancement_results.csv`。Residual MLP 在 $k = 10$ 和 $k = 100$ 上显著降低状态 RMSE; 在 $k = 500$ 下仍优于 Direct MLP, 但误差已经较大, 说明残差学习不能消除混沌系统长期预测困难。

表 5: Direct MLP 与 Residual MLP 的代表性结果 (来自 `model_enhancement_results.csv`)。Residual MLP 学习状态增量, 在中短期更符合连续动力系统局部变化结构。

Horizon	模型	State RMSE	R_{mean}^2
10	Direct MLP	0.4130	0.9993
10	Residual MLP	0.0833	1.0000
100	Direct MLP	2.1529	0.9800
100	Residual MLP	0.8306	0.9970
500	Direct MLP	14.0980	0.1245
500	Residual MLP	12.0584	0.3609




图 4: Residual MLP 与 Direct MLP 在不同 horizon 下的对比。残差学习在短中期明显降低误差，但较长 horizon 下仍受到混沌误差放大的限制。

4.5 不完美物理模型的预测误差

Hybrid 实验中，真实系统使用 $\rho = 28$ ，不完美物理模型使用 $\rho = 26$ 。该物理模型并非完全错误：它仍保留 Lorenz 方程结构，只是关键参数存在偏差。单独使用该模型时，一步 State RMSE 为 0.0786，但在 recursive rollout 中会逐渐偏离真实轨迹；500 步窗口内有效预测时间约为 0.3465 个 Lyapunov time，最终累计 State RMSE 为 19.6795。这些数值来自 `results/hybrid_metrics.csv` 和 `results/valid_prediction_time.csv`。

4.6 Hybrid RF 与 Hybrid MLP 的残差修正效果

表 6 比较不完美物理模型、Pure ML Residual MLP、Hybrid RF 和 Hybrid MLP 的一步预测结果，数值来自 `results/hybrid_metrics.csv`。Hybrid correction 将机器学习模型用于学习物理模型残差，在当前 $\rho = 26$ 参数偏差设定下显著降低一步误差。

表 6: 不完美物理模型、Pure ML 与 Hybrid correction 的一步状态预测结果（来自 `hybrid_metrics.csv`）。

模型	State RMSE	R_{mean}^2
Imperfect physics	0.0786	0.9999746657
Pure ML Residual MLP	0.0102	0.9999995570
Hybrid RF	0.0003	0.9999999996
Hybrid MLP	0.0006	0.9999999986




图 5: 不完美物理模型、Pure ML 与 Hybrid correction 的一步状态 RMSE 对比。Hybrid RF 和 Hybrid MLP 显著降低了由 $\rho = 26$ 参数偏差引入的一步误差。

在 500 步 recursive rollout 中, Hybrid correction 也保持了更长有效预测时间。表 7 的数值来自 `results/valid_prediction_time.csv`。Hybrid RF 和 Hybrid MLP 在 500 步窗口内均未超过经验失效阈值, 因此 2.2502 个 Lyapunov time 是当前窗口下界, 而不是理论上限。

表 7: 500 步 rollout 中的有效预测时间 (来自 `valid_prediction_time.csv`)。Hybrid correction 在当前参数偏差设置下明显减缓误差累积。

模型	有效步数	物理时间	Lyapunov time	最终累计 State RMSE
Imperfect physics	77	0.3850	0.3465	19.6795
Pure ML Residual MLP	413	2.0652	1.8587	11.1571
Hybrid RF	500	2.5003	2.2502	0.7774
Hybrid MLP	500	2.5003	2.2502	0.0862




图 6: Hybrid correction 在递归多步推演中的累计状态 RMSE。Hybrid RF 和 Hybrid MLP 在当前 $\rho = 26$ 参数偏差设定下保持更低误差，但该结论不应外推到所有物理模型错误。

5 讨论

5.1 为什么简单线性模型不够

Lorenz 系统包含 xz 、 xy 等非线性项，系统演化不是简单线性映射。Linear Regression 可以作为短期局部近似和课程回归基线，但当 prediction horizon 增大时，它无法表达非线性耦合带来的复杂状态变化，因此误差迅速升高。

5.2 为什么神经网络和树模型短期有效但长期受限

短时间内，连续动力系统的状态转移具有局部连续性和平滑性，Random Forest 和 MLP 可以拟合这种局部非线性映射。这解释了它们在短 horizon 下优于线性模型的现象。但 Lorenz 系统具有初值敏感性，小误差会在动力系统中被放大。recursive rollout 还会让模型不断使用自己的预测作为输入，使得输入分布逐渐偏离训练时的真实轨迹分布。

5.3 为什么学习残差比直接预测更适合连续动力系统

对连续动力系统而言，短时间内未来状态通常可以看作“当前状态 + 状态变化量”。Residual MLP 学习 $\mathbf{s}_{t+k} - \mathbf{s}_t$ ，比直接学习 $\mathbf{s}_{t+k}$ 更贴近数值积分思想，也让模型集中拟合局部变化。因此，它在 $k = 10$ 和 $k = 100$ 上明显优于 Direct MLP。然而，当 $k = 500$ 时，系统已经经历较长非线性演化，残差学习仍无法避免混沌系统长期逐点预测困难。

5.4 Hybrid correction 与 AI for Science 的关系

现实科学问题中通常已有近似物理模型，而不是完全从零开始。Hybrid correction 的价值在于：机器学习不必学习全部动力学规律，而是学习物理模型的系统误差。本文中，不完美物理模型只把 ρ 从 28 改为 26，仍会在 rollout 中逐渐偏离真实轨迹；Hybrid RF 和 Hybrid MLP 学习该偏差带来的一步残差后，显著降低误差并延长有效预测时间。这体现了“物理模型 + 数据驱动修正”的科学机器学习思想。

5.5 局限性

本文仍是 AI 导论课程规模的小项目。训练数据来自有限参数和有限初始条件下的模拟轨迹；Residual MLP 的网络结构只做了有限比较；Hybrid correction 只测试了 $\rho = 26$ 这一种参数偏差；valid prediction time 使用经验阈值而非唯一标准。因此，本文结论应限定为当前实验设置下的预测边界分析，不能推广为任意混沌系统或任意物理模型错误都可由机器学习修正。

6 结论

本文以 Lorenz 混沌系统为对象，把 AI 导论课程中的回归、树模型和神经网络方法用于监督学习预测。实验表明，Linear Regression、Random Forest 和 MLP 可以用于短期状态预测，但普通黑箱模型在长 prediction horizon 和 recursive rollout 中会受到混沌误差放大限制。Residual MLP 通过学习状态增量改善了中短期预测；Hybrid correction 通过学习不完美物理模型残差，在当前 $\rho = 26$ 参数偏差设定下显著改善一步预测和短中期 rollout，展示了机器学习辅助物理模型修正的 AI for Science 价值。

A 超参数设置

本文使用的主要实现来自 scikit-learn [2]。Linear Regression 使用默认最小二乘设置；Random Forest 使用 notebook 中保存的实验设置；Direct MLP 和 Residual MLP 使用多层感知机回归器，并在模型增强实验中比较了不同隐藏层规模和激活函数。输入标准化器只在训练集上拟合。完整可复现实验代码保存在 `lorenz_chaos_prediction.ipynb`，主要数值结果保存在 `results/*.csv`。

B 额外模型结果

Persistence Model 只作为 naive baseline：它直接用当前状态作为未来状态预测，能反映短时间连续性，但不作为主文重点。ESN 作为 reservoir computing 对照保留在结果文件中；在当前轻量设置下，ESN 没有稳定超过 Residual MLP，且解释成本高，因此不放入主

线。MLP 激活函数、层数和 hidden size 消融结果保存在 `results/model_enhancement_results.csv`, 主文只选取 Direct MLP 与 Residual MLP 的代表性对比。

C LLM 辅助说明

本项目使用 LLM 辅助完成选题讨论、实验结构设计、代码组织建议和报告语言整理。LLM 未直接生成实验数值;报告中的指标均以 Python 程序输出的 `results/*.csv` 和 `results/summary.json` 为准。为减少手写表格与 CSV 不一致,本文新增 `scripts/generate_report_t` 可从结果文件生成 `results/generated_report_tables.tex` 供核对。

D 未来工作: SINDy 方程发现

未来可以进一步引入 SINDy 等动力学方程识别方法,从数据中恢复显式控制方程。该方向有助于提升模型可解释性,但它不属于本文 AI 导论课程模型主线,因此本文只作为未来工作提及,不在主文展开。

参考文献

- [1] Lorenz, E. N. (1963). Deterministic nonperiodic flow. *Journal of the Atmospheric Sciences*, 20(2), 130–141.
- [2] Pedregosa, F., Varoquaux, G., Gramfort, M., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, M., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [3] Virtanen, P., Gommers, R., Oliphant, M., Haberland, M., Reddy, T., Cournapeau, D., Peterson, P., Weckesser, W., Bright, J., van der Walt, S., Brett, M., Wilson, J., Millman, K., Mayorov, N., Nelson, A., Jones, E., Kern, R., Larson, E., Carey, C., Polat, I., Feng, Y., Moore, E., VanderPlas, J., Laxalde, D., Perktold, J., Cimrman, R., Henriksen, I., Quintero, E., Harris, C., Archibald, A., Ribeiro, A., Pedregosa, F., & van Mulbregt, P. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272.
- [4] Strogatz, S. H. (2015). *Nonlinear Dynamics and Chaos: With Applications to Physics, Biology, Chemistry, and Engineering*. Westview Press.